

HealthSearch

Relatório técnico - Laboratório Prático 05

1. O que foi desenvolvido

O HealthSearch é um protótipo de busca para documentos médicos. Ele ajuda um profissional a encontrar uma orientação clínica mesmo quando a consulta usa uma palavra diferente daquela que aparece no documento. Ao mesmo tempo, preserva a precisão necessária para localizar códigos e termos específicos, como COD-ECG-12D.

A aplicação reúne seis documentos fixos: protocolo de emergência ECG, farmacologia cardíaca, hipertensão arterial, AVC isquêmico, reanimação RCR e procedimentos gerais de UTI. A interface foi feita em Streamlit e está concentrada no arquivo healthsearch_app.py.

2. Como a busca funciona

2.1. 1. Preparação do texto

O sistema coloca o texto em letras minúsculas, remove caracteres que atrapalham a comparação e elimina palavras muito comuns da língua portuguesa. Assim, a busca se concentra nos termos mais informativos.

2.2. 2. Busca por palavras: BM25

O BM25 considera a frequência das palavras e evita favorecer injustamente documentos muito longos. Os controles k_1 e b ficam na barra lateral: k_1 ajusta o efeito da repetição de uma palavra, e b ajusta a penalização pelo tamanho do documento.

2.3. 3. Busca por significado: embeddings

Na busca semântica, cada documento e a consulta são transformados em uma representação numérica chamada embedding. O sistema compara essas representações pela similaridade de cosseno. Dessa forma, consultas como “ataque cardíaco” podem encontrar um texto que use “infarto agudo do miocárdio”.

2.4. 4. Combinação dos resultados: RRF

O RRF combina as posições obtidas pelos dois métodos, sem misturar diretamente suas escalas de pontuação. A fórmula utilizada é:

$$\text{Score_RRF(D)} = \alpha / (60 + \text{Rank_BM25}) + (1 - \alpha) / (60 + \text{Rank_Semântico})$$

O valor α controla o equilíbrio: valores maiores dão mais importância ao BM25; valores menores dão mais importância à busca semântica. A constante de suavização usada é $k_RRF = 60$.

3. Exemplo de consulta

Considere a consulta “ataque cardíaco”. O BM25 procura as palavras exatas e tende a destacar o documento que contém “infarto”. A busca semântica entende que os dois termos estão relacionados e também pode recuperar a mesma diretriz, mesmo sem coincidência literal. O RRF observa as duas listas e produz uma ordem única.

Consulta	O que o BM25 valoriza	O que a busca semântica ajuda a encontrar
ECG-12D	O código exato	O contexto de exames cardíacos
infarto	A palavra presente no texto	A relação com ataque cardíaco
pressão arterial	Os termos da consulta	A relação com hipertensão
AVC isquêmico	A correspondência literal	A relação com acidente vascular cerebral

HealthSearch

Resultados e organização da solução

4. O que aparece na tela

A Matriz Comparativa mostra a posição de cada documento nos dois rankings e no resultado final. A aba Busca Léxica apresenta os scores BM25. A aba Busca Semântica apresenta as similaridades de cosseno. A aba Busca Híbrida mostra o score RRF e o trecho clínico de cada documento.

Como recurso adicional, o checkbox Cross-Encoder pode reordenar os três primeiros candidatos do RRF. Esse modelo analisa diretamente o par formado pela consulta e pelo texto e permite comparar a ordem antes e depois do re-ranking.

5. Organização da solução

Componente	Responsabilidade
Pré-processamento e BM25	Tokenização em português, stopwords e calibração de k1 e b
Busca semântica	Geração de embeddings e cálculo da similaridade de cosseno
RRF e interface	Fusão dos rankings, abas comparativas, métricas e documentação

Em resumo, o protótipo une correspondência exata e compreensão de contexto. Isso reduz as limitações de usar apenas palavras-chave ou apenas busca semântica em um cenário de saúde.